UNIVERSIDAD TÉCNICA DE MANABÍ
Fundada en 1952

TÍTULO:

Navigating the Data-Rich Landscape of Online Learning: Insights and Predictions from ASSISTments

FACULTAD:

Facultad de Ciencias Informáticas

ENLACE DEL CASO DE ESTUDIO:

https://doi.org/10.5281/zenodo.12729826

REPOSITORIO DEL CASO DE ESTUDIO:

https://github.com/DSAatUSU/EDMCup2023

PERÍODO ACADÉMICO:

SEPTIEMBRE 2026 - ENERO 2027

INTEGRANTES:

GARCÍA INTRIAGO ZHARICK MONSERRATE (COORDINADORA)

MOREIRA PÉREZ ELKIN JEACOMAN

PÁRRAGA MEZA JOSÉ ANDRÉS

SORNOZA LOAIZA ROGER FEDERICK

VERA GARCÍA RAFAEL EDUARDO

PORTOVIEJO - MANABÍ - ECUADOR

2026 - 2027

Título del caso de estudio: Navigating the Data-Rich Landscape of Online Learning: Insights and Predictions from ASSISTments

Enlace del caso de estudio: https://doi.org/10.5281/zenodo.12729826

Tipo de modelo computacional implementado: Modelo de Aprendizaje Automático Supervisado de Clasificación Binaria, implementado mediante el algoritmo de ensamble Random Forest.

1. Comprensión del Negocio y de los Datos (CRISP-ML(Q))

Problema

El problema que se presenta es la dificultad para detectar tempranamente a estudiantes que no dominan las habilidades. Se requiere un modelo predictivo, basado en logs de práctica, para anticipar resultados en problemas de fin de unidad y alertar a los docentes.

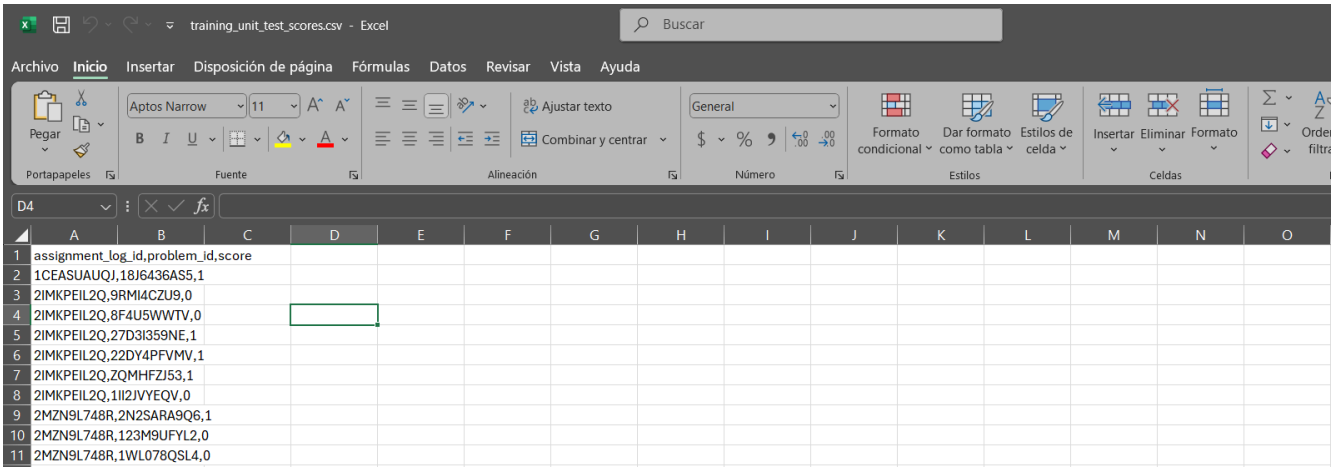
Objetivos de minería de datos

1. Entrenar un Random Forest para predecir si un estudiante acertará o fallará un problema específico de fin de unidad. Su fin es generar alertas tempranas para el docente, no calcular notas globales ni predecir abandono.
2. Evaluar el rendimiento y la capacidad discriminativa del modelo mediante matriz de confusión, métricas por clase y ROC-AUC, con atención al recall de la clase `score = 0`.

Conjunto de datos: La unidad de análisis es la interacción estudiante-problema de fin de unidad (predicción por problema, no por promedio general).

Etiquetado de la variable objetivo

Las etiquetas se conservan según la definición original del caso de estudio ASSISTments. Se asigna score = 1 cuando el estudiante resuelve correctamente el problema en el primer intento sin solicitar ayuda, o cuando completa correctamente una actividad abierta. En los demás casos se asigna score = 0. Por tanto, el equipo no creó nuevas etiquetas; utiliza la variable objetivo provista por el dataset.



Captura 1. Extracto del csv training_unit_test_scores

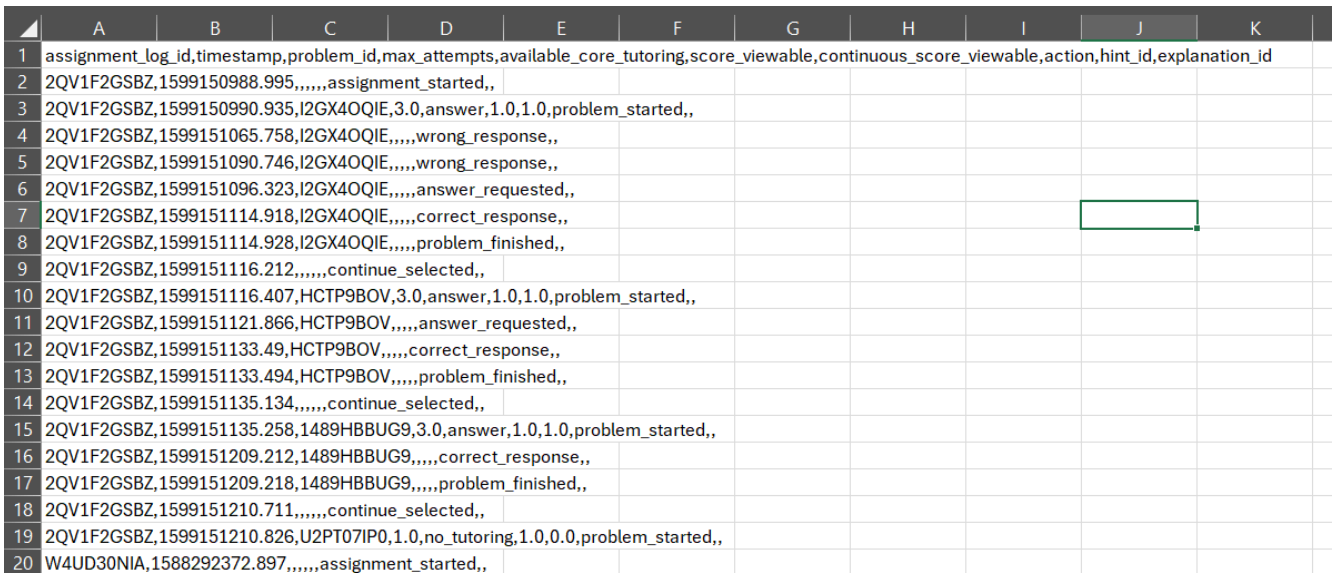
Definición de Variables

Tabla 1. Descripción de los atributos

No.	Atributo	Descripción
1	score	Resultado por problema de evaluación: 0 no exitoso; 1 exitoso.
2	action_answer_requested	Conteo de eventos de solicitud de respuesta.
3	action_wrong_response	Conteo de respuestas incorrectas registradas.
4	action_correct_response	Conteo de respuestas correctas registradas.
5	notfinish_percent	Proporción de asignaciones de práctica relacionadas que quedaron sin finalizar.
6	available_core_tutoring_other	Conteo de eventos asociados a la categoría de tutoría “Other”.
7	action_continue_selected	Conteo de selecciones de la acción “continuar”.
8	action_problem_finished	Conteo de problemas finalizados.
9	action_problem_started	Conteo de problemas iniciados.
10	available_core_tutoring_no_tutoring	Conteo de eventos asociados a “No tutoring”.
11	available_core_tutoring_answer	Conteo de eventos asociados a la tutoría de respuesta.
12	available_core_tutoring_hint	Conteo de eventos asociados a la tutoría de pista.
13	action_assignment_finished	Conteo de asignaciones finalizadas.
14	action_open_response	Conteo de respuestas abiertas registradas.x
15	problem_text_bert_pca_1	Segunda componente principal de la representación vectorial del texto del problema.
16	action_assignment_started	Conteo de asignaciones iniciadas.

2. Preparación de los Datos

Datos crudos de entrada



	A
1	assignment_log_id,timestamp,problem_id,max_attempts,available_core_tutoring,score_viewable,continuous_score_viewable,action,hint_id,explanation_id
2	2QV1F2GSBZ,1599150988.995,,,,,,assignment_started,,
3	2QV1F2GSBZ,1599150990.935,I2GX4OQIE,3.0,answer,1.0,1.0,problem_started,,
4	2QV1F2GSBZ,1599151065.758,I2GX4OQIE,,,,,wrong_response,,
5	2QV1F2GSBZ,1599151090.746,I2GX4OQIE,,,,,wrong_response,,
6	2QV1F2GSBZ,1599151096.323,I2GX4OQIE,,,,,answer_requested,,
7	2QV1F2GSBZ,1599151114.918,I2GX4OQIE,,,,,correct_response,,
8	2QV1F2GSBZ,1599151114.928,I2GX4OQIE,,,,,problem_finished,,
9	2QV1F2GSBZ,1599151116.212,,,,,,continue_selected,,
10	2QV1F2GSBZ,1599151116.407,HCTP9BOV,3.0,answer,1.0,1.0,problem_started,,
11	2QV1F2GSBZ,1599151121.866,HCTP9BOV,,,,,answer_requested,,
12	2QV1F2GSBZ,1599151133.49,HCTP9BOV,,,,,correct_response,,
13	2QV1F2GSBZ,1599151133.494,HCTP9BOV,,,,,problem_finished,,
14	2QV1F2GSBZ,1599151135.134,,,,,,continue_selected,,
15	2QV1F2GSBZ,1599151135.258,1489HBBUG9,3.0,answer,1.0,1.0,problem_started,,
16	2QV1F2GSBZ,1599151209.212,1489HBBUG9,,,,,correct_response,,
17	2QV1F2GSBZ,1599151209.218,1489HBBUG9,,,,,problem_finished,,
18	2QV1F2GSBZ,1599151210.711,,,,,,continue_selected,,
19	2QV1F2GSBZ,1599151210.826,U2PT07IP0,1.0,no_tutoring,1.0,0.0,problem_started,,
20	W4UD30NIA,1588292372.897,,,,,,assignment_started,,

Captura 2. Extracto de action_logs.csv, fuente cruda de eventos de práctica.

Preprocesamiento:

Selección e integración: Se trabajó con una muestra reproducible de 3.000 estudiantes (semilla 42) y se conservaron las particiones train y evaluation. Los registros de actividad, asignaciones, secuencias y problemas se vincularon mediante sus identificadores.

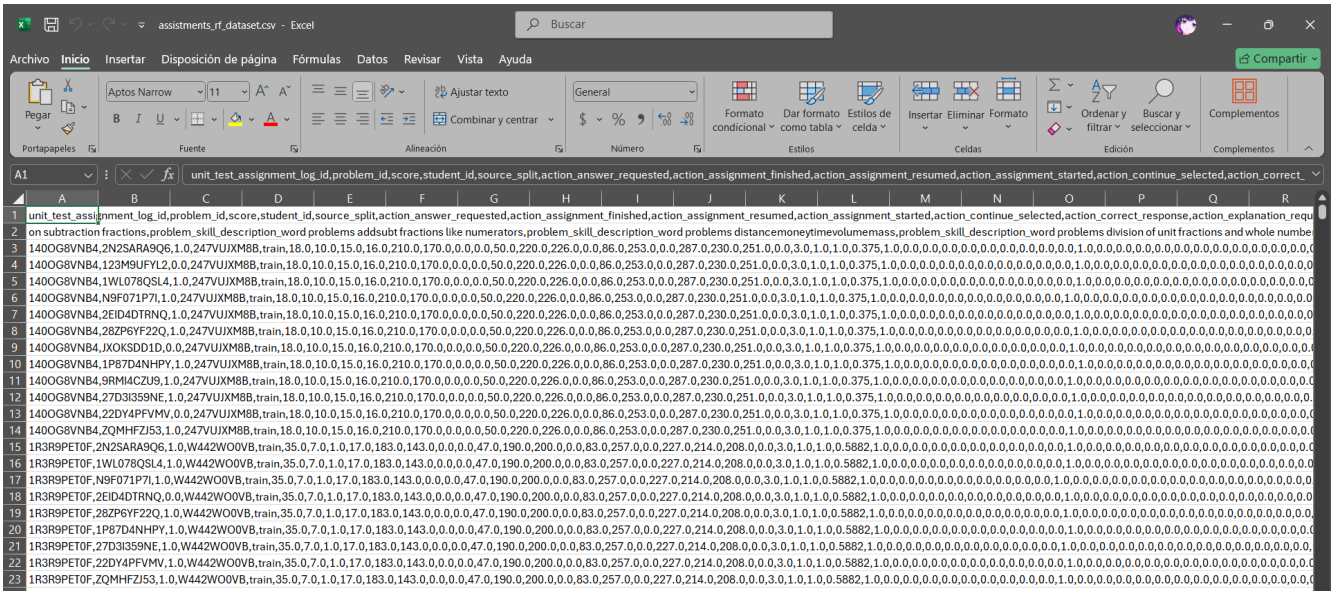
Agregación: action_logs.csv se procesó en bloques de 300.000 filas. Se calcularon 14 conteos de acciones (action_*) y cinco conteos de disponibilidad de tutoría (available_core_tutoring_*), además de notfinish_percent, multipart_id_frequency y los valores más frecuentes de max_attempts, score_viewable y continuous_score_viewable.

Transformación y limpieza:

Tabla 2. Reglas de transformación y tratamiento de datos.

Dato de entrada	Representación para el modelo
Categorías de secuencia y problema	Codificación 0/1 por categoría con pandas.get_dummies; 666 columnas.
Vector problem_text_bert_pca	32 variables numéricas: problem_text_bert_pca_0 a problem_text_bert_pca_31.
Valores ausentes o no válidos	Conteos: 0; categorías: na/other; valores numéricos faltantes, no convertibles o infinitos: -1.
Tipo de predictores	float32.

Resultado: El CSV consolidado contiene 51.042 filas, 3.000 estudiantes y 727 columnas: 722 predictoras y cinco columnas de identificación, partición y etiqueta. score conserva sus clases 0/1 y se excluye de los predictores.


assistments_rf_dataset.csv - Excel
Buscar
Archivo Inicio Insertar Disposición de página Fórmulas Datos Revisar Vista Ayuda
Compartir
Pegar
Aptos Narrow
11
Ajustar texto
Combinar y centrar
General
Formato condicional
Dar formato como tabla
Estilos de celda
Insertar
Eliminar
Formato
Ordenar y filtrar
Buscar y seleccionar
Complementos
Portapapeles
Fuente
Alineación
Número
Estilos
Celdas
Edición
Complementos
A1
unit_test_assignment_log_id,problem_id,score,student_id,source_split,action_answer_requested,action_assignment_finished,action_assignment_resumed,action_assignment_started,action_continue_selected,action_correct_
unit_test_assignment_log_id,problem_id,score,student_id,source_split,action_answer_requested,action_assignment_finished,action_assignment_resumed,action_assignment_started,action_continue_selected,action_correct_response,action_explanation_requ
on subtraction fractions,problem_skill_description_word problems addsubt fractions like numerators,problem_skill_description_word problems distancemoneytimevolumemass,problem_skill_description_word problems division of unit fractions and whole numbe
140OG8VNB4,2N2SARA9Q6,1.0,247VUJXM8B,train,18.0,10.0,15.0,16.0,210.0,170.0,0.0,0.0,0.0,50.0,220.0,226.0,0.0,86.0,253.0,0.0,287.0,230.0,251.0,0.0,3.0,1.0,1.0,0.375,1.0,0.0,0.0,0

```python
train_mask = df['source_split'].eq('train')
eval_mask = df['source_split'].eq('evaluation')
if eval_mask.any() and train_mask.any():
    train_idx = np.flatnonzero(train_mask.to_numpy())
    test_idx = np.flatnonzero(eval_mask.to_numpy())
    evaluation_name = 'Partición evaluation del CSV'
else:
    train_labeled_idx = np.flatnonzero(train_mask.to_numpy())
    groups = df.loc[train_labeled_idx, 'student_id'].astype('string').to_numpy()
    if len(np.unique(groups)) < 2:
        raise ValueError('Se necesitan al menos dos estudiantes etiquetados para validar.')
    splitter = GroupShuffleSplit(n_splits=1, test_size=0.20, random_state=SEED)
    relative_train, relative_test = next(splitter.split(
        X.iloc[train_labeled_idx], y.iloc[train_labeled_idx], groups=groups
    ))
    train_idx = train_labeled_idx[relative_train]
    test_idx = train_labeled_idx[relative_test]
    evaluation_name = 'Validación interna por estudiante (80/20)'

X_train = X.iloc[train_idx]
X_test = X.iloc[test_idx]
y_train = y.iloc[train_idx].to_numpy()
y_test = y.iloc[test_idx].to_numpy()
if len(np.unique(y_train)) < 2:
    raise ValueError('El entrenamiento quedó con una sola clase. Aumenta MAX_STUDENTS en preparación.')
if len(test_idx) == 0:
    raise ValueError('La partición de evaluación está vacía.')

rf = RandomForestClassifier(
    n_estimators=N_ESTIMATORS,
    max_depth=19,
    min_samples_split=10,
    min_samples_leaf=2,
    max_features='sqrt',
    bootstrap=True,
    random_state=SEED,
    n_jobs=-1
)
```

Captura 4. Extracto del código de modelado en Google Colab

4. Evaluación

Aclaración de alcance: El presente informe es una replicación reducida del flujo predictivo con Random Forest. El artículo original incluye otros modelos y análisis de representaciones de grafos, reportando para Random Forest (con variables diseñadas manualmente) un accuracy de 0,71402 y un AUC de 0,77005. La diferencia en los resultados obtenidos a continuación (accuracy=0,7022 y AUC=0,7528) es previsible dado que aquí se usó una muestra de 3.000 estudiantes y una preparación de variables adaptada.

Métricas de Evaluación Aplicadas:

- **Exactitud (accuracy):** 70,22%
- **Precision macro:** 0,692
- **Recall macro:** 0,680
- **F1-Score macro:** 0,683
- **Recall de clase minoritaria (score=0):** 55,70%
- **ROC-AUC:** 0,753

Interpretación de Resultados Mediante Gráficos:

- **Distribución del resultado real (Figura 1)**

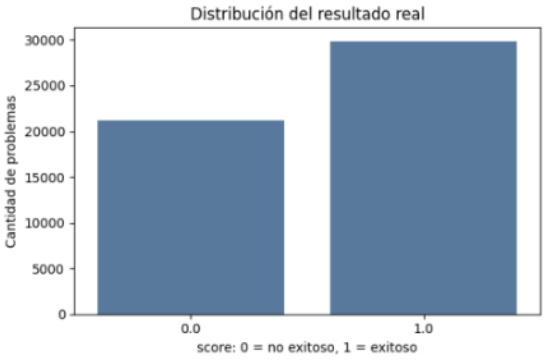


Figura 1. Carga del CSV objetivo y distribución de la etiqueta score.

- **Resumen de rendimiento de Random Forest (Figura 2)**

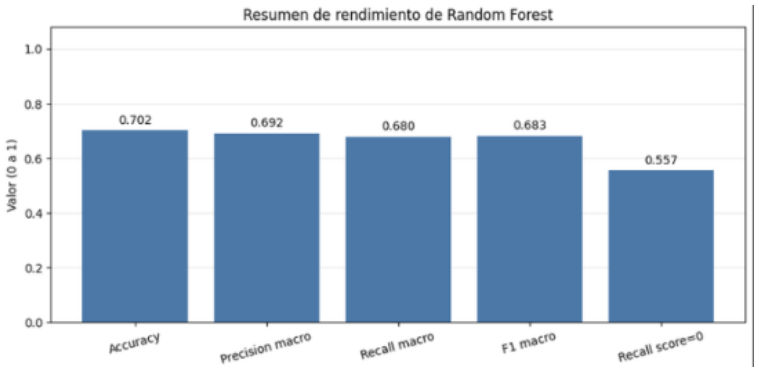


Figura 2. Resumen de métricas del Random Forest.

En la partición de evaluación, Random Forest alcanzó accuracy=0,7022; precisión macro=0,6923; recall macro=0,6797 y F1 macro=0,6828. Para score=0, el recall fue 0,5570 y el ROC-AUC 0,7528. Para score=1, precisión=0,7241, recall=0,8023 y F1=0,7612. La Figura 2 resume las métricas principales.

- **Matriz de Confusión y curva ROC (Figuras 3 y 4)**

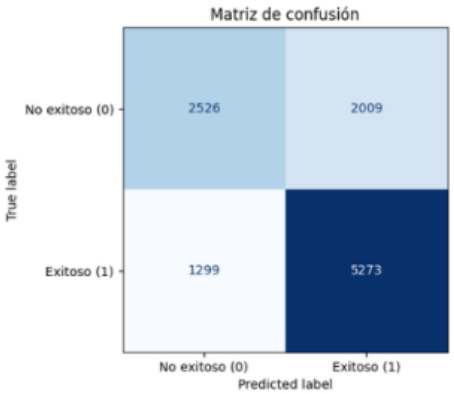


Figura 3. Matriz de confusión

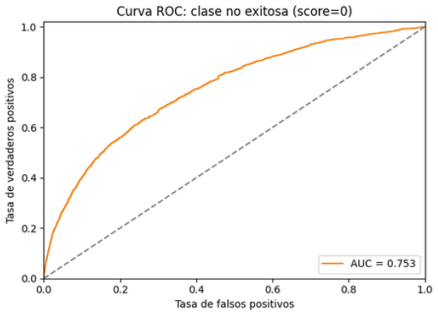


Figura 4. Curva ROC para score=0

La matriz de confusión se interpreta con filas como clase real y columnas como clase predicha. Para la clase score = 0, el modelo identifica correctamente 2 526 de 4 535 casos y clasifica erróneamente 2 009 como score = 1.

Para la clase score = 0, la precisión es 66,04 %, el recall es 55,70 % y el F1 es 60,43 %. Para la clase score = 1, la precisión es 72,41 %, el recall es 80,23 % y el F1 es 76,12 %.

El modelo obtuvo accuracy = 70,22 %, precisión macro de 69,23 %, recall macro de 67,97 %, F1 macro de 68,28 % y AUC de 0,7528. El AUC se calcula con las probabilidades de score = 0 y mide la capacidad del modelo para diferenciar ambas clases en distintos umbrales.

El principal punto de mejora es el recall de la clase score = 0, ya que el modelo todavía omite parte de los casos de fallo.

- **Importancia Relativa de Variables (Figura 5)**

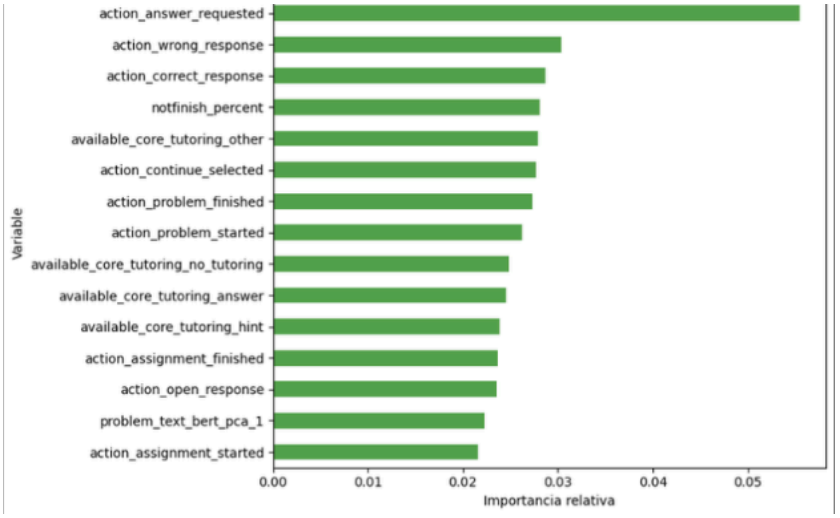


Figura 5. Quince variables con mayor importancia relativa en Random Forest.

La Figura 5 presenta las 15 variables con mayor importancia según el Random Forest. Entre las variables destacadas predominan acciones de práctica y solicitud de ayuda, lo que sugiere que la interacción del estudiante aporta información útil para la predicción.

Estas importancias indican asociación con la reducción de impureza del modelo. No muestran dirección del efecto ni permiten afirmar causalidad.

Nota del caso:

El caso de estudio presenta extracción de variables, modelado y evaluación experimental pero no describe un sistema desplegado, monitoreo automático ni controles SQA operativos. Por ello, las fases 5, 6 y 7 las presentaremos como propuestas para una implementación futura usando referencias de otros estudios de caso.

Despliegue y Aseguramiento de Calidad Transversal

El caso de estudio analizado es un entorno experimental offline que no contempla fases implementadas de Despliegue, Monitoreo ni Aseguramiento de Calidad (QA). En base a estudios de sistemas de alerta educativa (Bañeres et al., 2023) y estabilidad analítica (Tiukhova et al., 2024), se plantea esta propuesta:

5.Despliegue: prototipo que recibe las 722 variables procesadas y genera score_predicho y sus probabilidades. Los casos con score = 0 se proponen como alertas para revisión del docente.

6. Monitoreo: en cada cohorte nueva se propone validar esquema, faltantes y distribución de variables. Cuando existan etiquetas reales, se recalculan métricas antes de reentrenar el modelo.

7. Aseguramiento de Calidad (QA) Transversal: Puntos de control estrictos:

Bañeres et al. (2023) implementan un sistema de alerta temprana que usa predicciones para apoyar intervenciones educativas. Tiukhova et al. (2024) analizan la estabilidad de las predicciones y de sus explicaciones. Por ello, para este proyecto se propone:

1. **Comprensión**: Definir el uso de la alerta para los casos con score = 0, el recall mínimo aceptable y el número tolerable de falsas alertas, siguiendo el enfoque de alerta temprana de Bañeres et al. (2023).

2. **Preparación:** Validar duplicados, faltantes y el esquema de los 722 predictores; documentar cada transformación para asegurar que los datos de nuevas cohortes sean comparables.
3. **Modelado:** Excluir score, identificadores y source_split de X; entrenar únicamente con train y registrar parámetros y semilla 42 para que el resultado sea reproducible.
4. **Evaluación**: Reportar métricas por clase y validar por estudiante. También se debe revisar la estabilidad de las variables importantes y de las explicaciones entre particiones o cohortes, como plantea Tiukhova et al. (2024).
5. **Despliegue:** Validar el esquema de entrada antes de predecir, registrar las predicciones y presentar las alertas al docente como apoyo para revisión e intervención, no como una decisión automática, en línea con Bañeres et al. (2023).
6. **Monitoreo:** Revisar deriva de datos, rendimiento y cambios en las variables importantes cuando existan etiquetas nuevas. Todo reentrenamiento debe validarse antes de utilizarse, para comprobar que la predicción conserva estabilidad.

Herramientas y Tecnologías Empleadas

El procesamiento y modelado se realizaron en Python mediante Pandas, NumPy, scikit-learn, Matplotlib y Seaborn, ejecutados en Jupyter Notebook y Google Colab. Se utilizó Random Forest para clasificación, métricas de clasificación, matriz de confusión, curva ROC y AUC.

Conclusiones

1.En conclusión, nuestro modelo Random Forest alcanzó una exactitud del 70,22%. Pero lo más interesante que descubrimos al revisar las variables importantes es que el comportamiento del alumno en la plataforma (por ejemplo, qué tanto pide las respuestas) predice mucho mejor su desempeño que el propio texto del problema. Esto nos comprueba que registrar y analizar estas interacciones de los estudiantes es clave para entender cómo les va a ir.

2.Si bien el área bajo la curva (AUC de 0,753) sustenta estadísticamente al modelo, la matriz de confusión y el bajo recobrado en la clase 0 (55,70%) indican un sesgo hacia la clase mayoritaria. Para ser implementado como un sistema real de intervención de calidad, se recomienda evaluar el umbral de decisión para un posible ajuste, ya que bajo la configuración actual el modelo clasifica como "exitosos" a un alto número de estudiantes en verdadero riesgo de fallar.

Anexos

Enlace del dataset: https://github.com/DSAatUSU/EDMCup2023

Enlace del código:
https://colab.research.google.com/drive/1pr4NYjK6fZnT9jouB0aeOcXaomso9-wn?usp=sharing#scrollTo=pa7nljCcEMGN

Referencias bibliográficas

Bañeres, D., Rodríguez-González, M. E., Guerrero-Roldán, A. E., & Cortadas, P. (2023). An early warning system to identify and intervene online dropout learners. *International Journal of Educational Technology in Higher Education*, 20, 3. https://doi.org/10.1186/s41239-022-00371-5

Tiukhova, E., et al. (2024). Explainable learning analytics: assessing the stability of student success prediction models by means of explainable AI. *Decision Support Systems*, 182, 114229. https://doi.org/10.1016/j.dss.2024.114229